Filtre de Kalman

Fusion de capteurs

A. Vaugeois

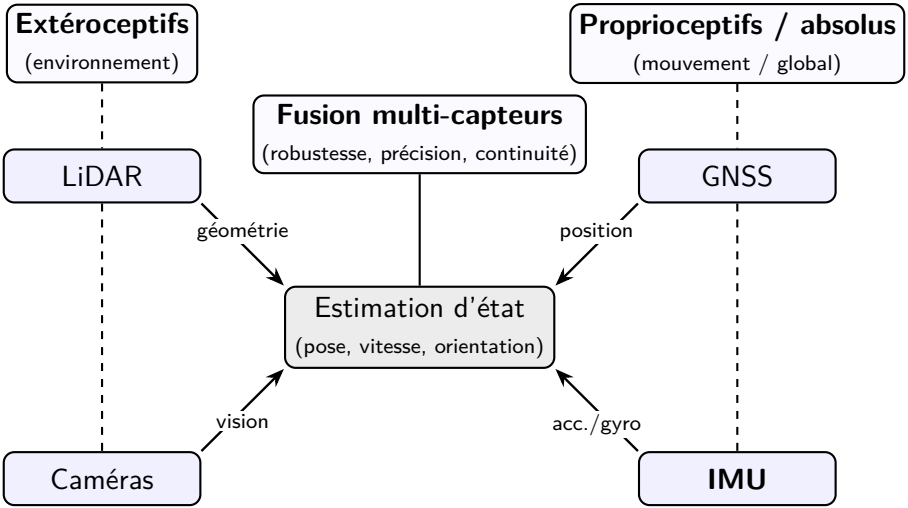
INSA Rouen - ISIA3

2025 - 2026

Sommaire

1. Introduction
2. Rappels statistiques : incertitude et corrélations
3. Estimateurs : du “meilleur linéaire” au gain de Kalman
4. Filtre de Kalman : cadre et modèle (partir de zéro)
5. Interprétation physique et géométrique
6. Extended Kalman Filter (EKF)

Capteurs pour la robotique mobile (rappels)



Problème central : **Incertitudes** de mesure ⇒ **estimation probabiliste de l'état**.

Notion d'état : Forme générale d'un système dynamique (rappels)

$$\begin{cases} \dot{\mathbf{x}}(t) = \mathbf{f}(\mathbf{x}(t), \mathbf{u}(t)) \\ \mathbf{y}(t) = \mathbf{g}(\mathbf{x}(t), \mathbf{u}(t)) \end{cases}$$

- $\mathbf{x}(t)$: **vecteur d'état**
- $\mathbf{u}(t)$: **entrée / commande**
- $\mathbf{y}(t)$: **mesures** (capteurs)
- $\mathbf{f}(\cdot)$: **dynamique** (modèle d'évolution)
- $\mathbf{g}(\cdot)$: **modèle de mesure**

Algorithme $\Rightarrow$ discrétisation
On approximera $\dot{\mathbf{x}}(t) = \frac{d\mathbf{x}}{dt}$ par la formule d'Euler :

$$\dot{\mathbf{x}}(t) = \frac{\mathbf{x}_{k+1} - \mathbf{x}_k}{\Delta t}$$

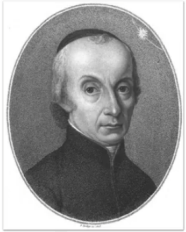
Méthode des moindres carrés - Origine historique : la redécouverte de Cérès (1801)

- 1er janvier 1801 : Giuseppe Piazzi observe un nouvel objet céleste.
- 24 observations sur 40 jours seulement.
- L'objet disparaît dans l'éclat du Soleil.

Problème

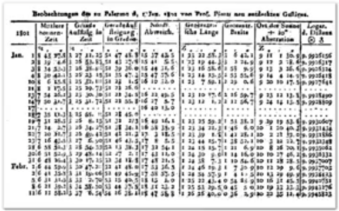
Comment prédire la position future d'un objet à partir de mesures bruitées et incomplètes ?

Carl Friedrich Gauss utilise une nouvelle méthode mathématique.



Giuseppe Piazzi





Piazzi's 24 observations

Principe de la méthode des moindres carrés

On cherche les paramètres θ qui minimisent : $\hat{\theta} = \arg\min_{\theta} \sum_{i=1}^{N} (y_i - f(x_i, \theta))^2$

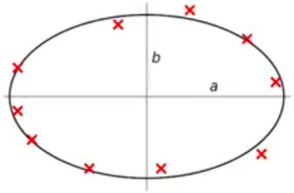
Interprétation

La meilleure estimation est celle qui minimise l'erreur quadratique totale.

- Méthode globale (toutes les données en même temps).
- Hypothèse implicite : données fixes et disponibles.
- Fondement de l'estimation statistique moderne.



Carl Friedrich Gauss
'Princeps mathematicorum'



Gauss used the **method of least squares** to determine the orbital parameters of Ceres.

Lien avec les probabilités

Si les erreurs sont gaussiennes :

$$\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$$

alors la solution des moindres carrés est équivalente à :

$$\hat{\theta} = \arg\max_{\theta} p(\theta \mid y)$$

Conclusion

Moindres carrés = Maximum de vraisemblance (si bruit gaussien)

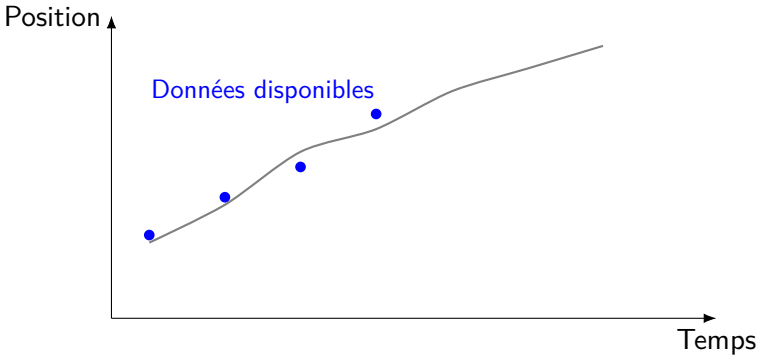
Limites des moindres carrés classiques

- Traitement **à posteriori** : toutes les données doivent être disponibles.
- Pas naturellement récursif : nouvelle mesure $\Rightarrow$ recalcul global.
- Ne modélise pas explicitement la dynamique temporelle.
- Ne met pas à jour une incertitude au cours du temps.

Que faire lorsque les mesures arrivent séquentiellement ?

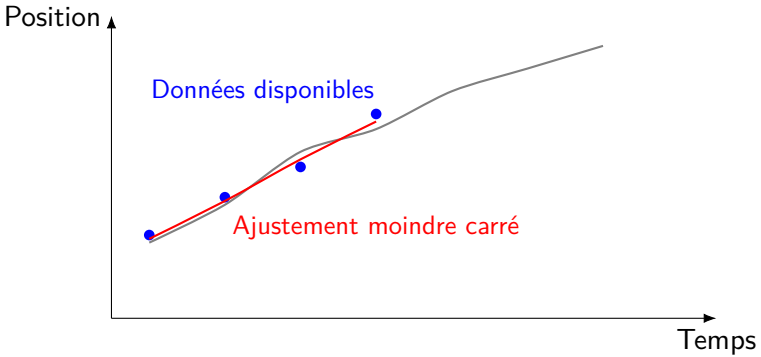
Les moindres carrés répondent à une question statique.
Kalman répond à la même question... mais dans le temps.

Du traitement batch à l'estimation récursive



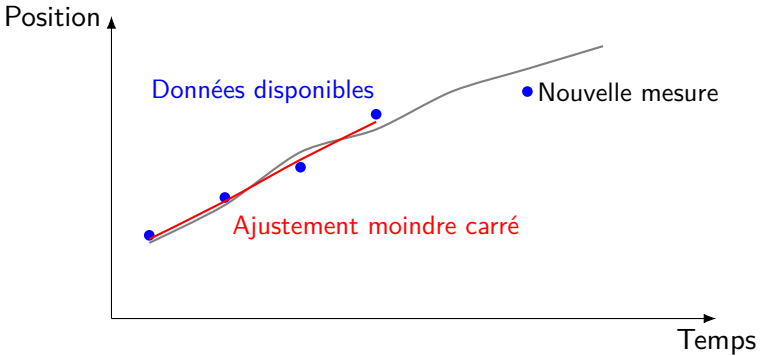
Moindres carrés : traitement global des données

Du traitement batch à l'estimation récursive



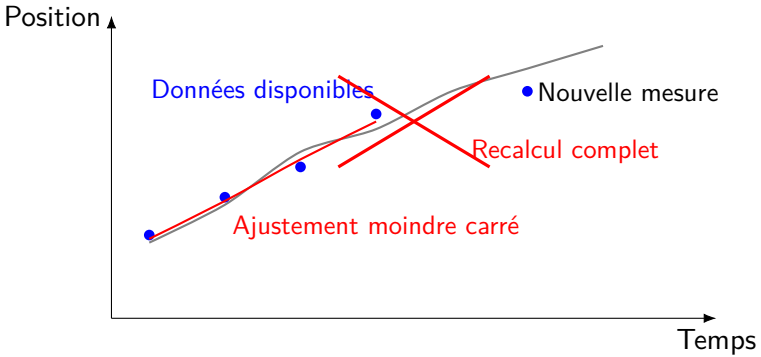
Ajustement optimal avec toutes les données disponibles

Du traitement batch à l'estimation récursive



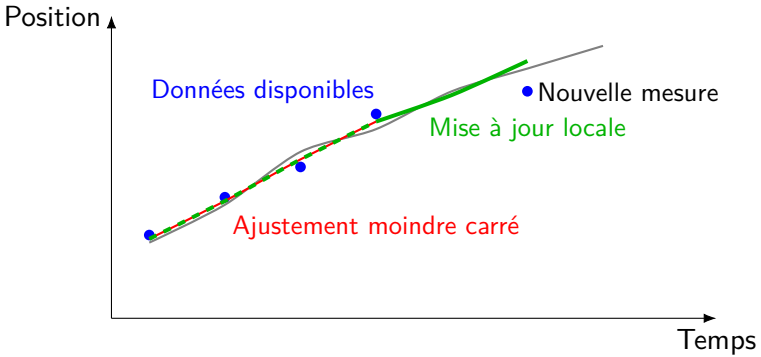
Une nouvelle donnée arrive

Du traitement batch à l'estimation récursive



LS classique $\Rightarrow$ recalcul complet

Du traitement batch à l'estimation récursive

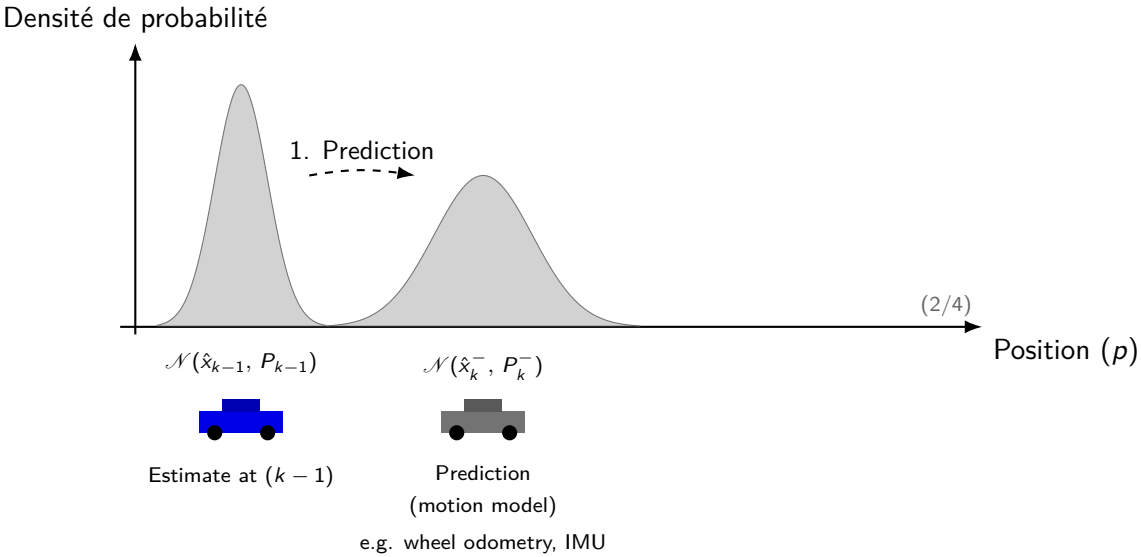


Idée : mise à jour récursive $\Rightarrow$ Kalman

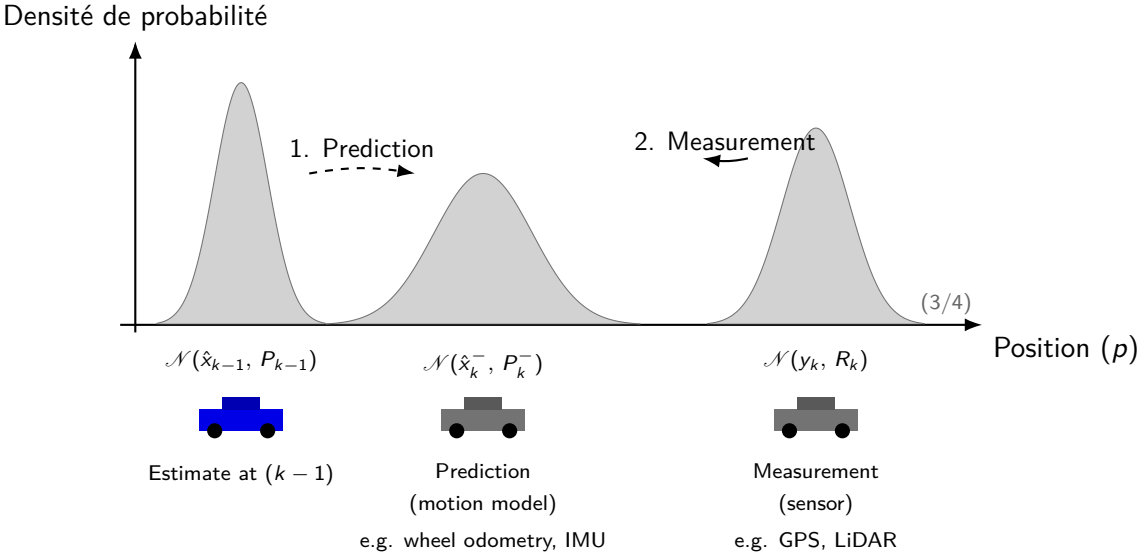
Intuition du filtre de Kalman : prédiction, mesure, fusion



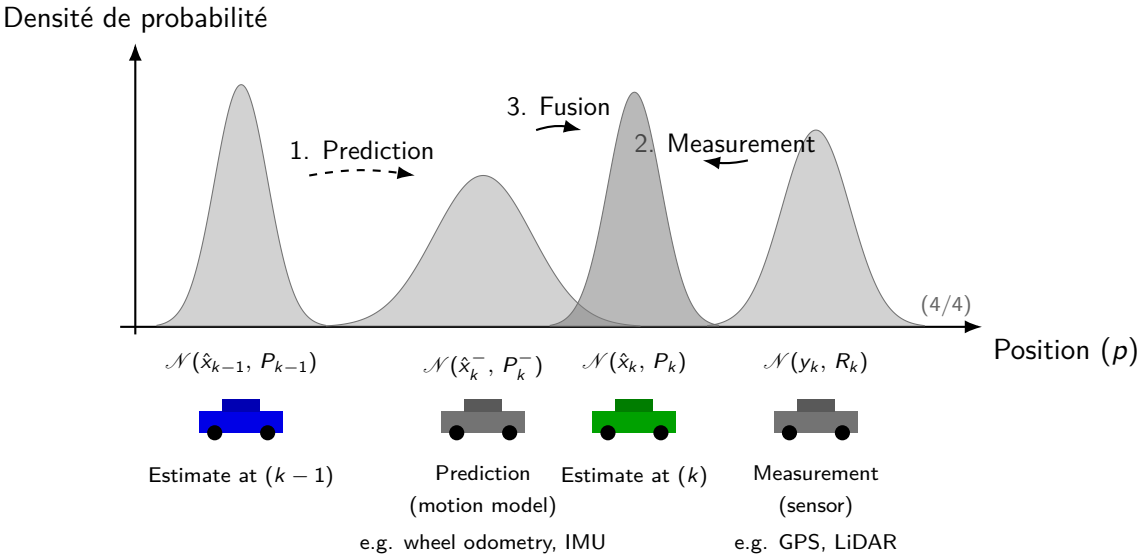
Intuition du filtre de Kalman : prédiction, mesure, fusion



Intuition du filtre de Kalman : prédiction, mesure, fusion



Intuition du filtre de Kalman : prédiction, mesure, fusion



Idée centrale du filtre de Kalman

Idée de base, à chaque instant :

$$\text{Nouvelle estimation} = \text{Ancienne estimation} + \text{Correction}$$

La vraie structure universelle

$$\text{Estimation} = \text{Prédiction} + \text{Gain} \times \text{Innovation}$$

Innovation = Mesure - Prédiction $\Leftrightarrow$ « Surprise »

Sommaire

1 Introduction

2 Rappels statistiques : incertitude et corrélations

3 Estimateurs : du “meilleur linéaire” au gain de Kalman

4 Filtre de Kalman : cadre et modèle (partir de zéro)

5 Interprétation physique et géométrique

6 Extended Kalman Filter (EKF)

Objectifs

- Clarifier : variables aléatoires $\Rightarrow$ **moyenne** et **incertitude**.
- Comprendre : **corrélation** vs **indépendance** (et pourquoi c'est crucial).
- Manipuler : **matrice variance–covariance** Σ (CM stat.) ou P (CM Kalman) (diagonale + hors-diagonale).
- Visualiser : incertitude multivariée $\Rightarrow$ **ellipse / ellipsoïde de confiance**.
- Faire le lien : Kalman = propagation / fusion de (μ, P).

Variable aléatoire : moyenne et variance

Soit X une variable aléatoire.

$$\mu_X = \mathbb{E}[X], \qquad \sigma_X^2 = \mathrm{Var}(X) = \mathbb{E}[(X - \mu_X)^2].$$

Interprétation physique :

- μ_X : valeur typique (centre) des réalisations.
- σ_X^2 : dispersion autour de ce centre $\Rightarrow$ niveau d'incertitude.
- Plus σ_X est grand, plus la mesure / estimation est **peu fiable**.

Exemple capteur : $y = x + v$ avec v bruit de mesure, $\mathbb{E}[v] = 0$, $\mathrm{Var}(v) = R$.

Covariance et corrélation : lien linéaire

Pour 2 v.a. (X, Y) :

$$\mathrm{Cov}(X, Y) = \mathbb{E}[(X - \mu_X)(Y - \mu_Y)]. \qquad \rho_{XY} = \frac{\mathrm{Cov}(X, Y)}{\sigma_X \sigma_Y} \in [-1, 1].$$

Lecture physique :

- $\mathrm{Cov}(X, Y) > 0$: quand X augmente, Y a tendance à augmenter.
- $\mathrm{Cov}(X, Y) < 0$: quand X augmente, Y a tendance à diminuer.
- $\mathrm{Cov}(X, Y) = 0$: **pas de lien linéaire** (mais pas forcément indépendants !).

Corrélation vs indépendance

Indépendance : $X \perp Y$ signifie que connaître X n'apporte aucune information sur Y.

$$X \perp Y \quad \Rightarrow \quad \mathrm{Cov}(X, Y) = 0.$$

Attention : la réciproque est **fausse en général** :

$$\mathrm{Cov}(X, Y) = 0 \not\Rightarrow X \perp Y.$$

Cas gaussien (très important pour Kalman) :
Si (X, Y) est **jointement gaussien**, alors

$$\mathrm{Cov}(X, Y) = 0 \quad \Longleftrightarrow \quad X \perp Y.$$

Idée : dans le monde gaussien, "pas de corrélation" $\approx$ "pas de lien exploitable".

Exemple contre-intuitif : non corrélés mais dépendants

Prenons $X \sim \mathcal{U}(-1, 1)$ uniforme, et définissons

$$Y = X^2.$$

Dépendance évidente : si X est proche de 0, alors Y est proche de 0 ; si $|X|$ est grand, Y est grand.

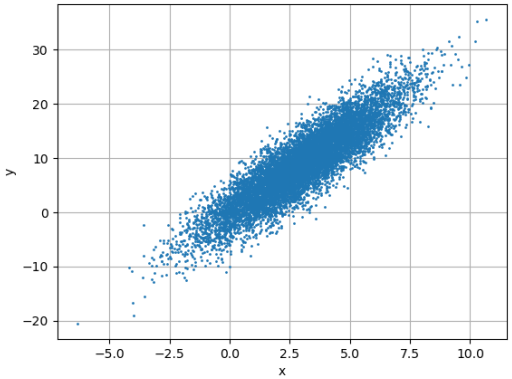
Mais :

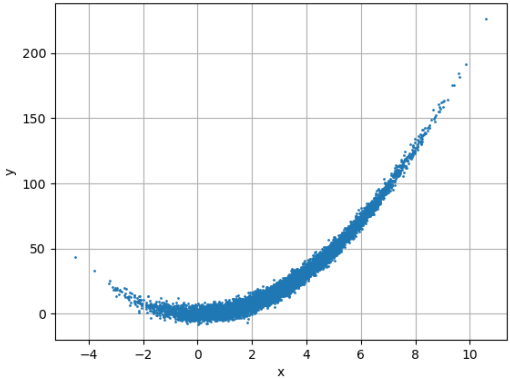
$$\mathrm{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] = \mathbb{E}[X^3] - 0 \cdot \mathbb{E}[Y] = 0,$$

car la densité est symétrique $\Rightarrow \mathbb{E}[X^3] = 0$.

Conclusion : absence de corrélation $\neq$ indépendance (sauf cas gaussien).

Exemples


30
20
10
0
−10
−20
y
−5.0
−2.5
0.0
2.5
5.0
7.5
10.0
x


200
150
100
50
0
y
−4
−2
0
2
4
6
8
10
x

Vecteur aléatoire : moyenne et matrice de covariance

Soit $\mathbf{X} = \begin{bmatrix} X_1 \\ \vdots \\ X_n \end{bmatrix} \in \mathbb{R}^n$.

$$\boldsymbol{\mu} = \mathbb{E}[\mathbf{X}], \qquad \boldsymbol{\Sigma}_{stat} = \boldsymbol{P}_{Kalman} = \mathrm{Cov}(\mathbf{X}) = \mathbb{E}\Big[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^\top\Big].$$

Lecture :

- $P_{ii} = \mathrm{Var}(X_i)$: incertitude sur la composante i.
- $P_{ij} = \mathrm{Cov}(X_i, X_j)$: couplage (linéaire) entre composantes.

Propriétés : $\boldsymbol{P} = \boldsymbol{P}^\top$, $\boldsymbol{P} \succeq 0$ (semi-définie positive).

P : diagonale vs hors-diagonale (interprétation capteurs)

Exemple d'état 2D **position–vitesse** :

$$\mathbf{x} = \begin{bmatrix} p \\ v \end{bmatrix}, \qquad \mathbf{P} = \begin{bmatrix} \mathrm{Var}(p) & \mathrm{Cov}(p,v) \\ \mathrm{Cov}(v,p) & \mathrm{Var}(v) \end{bmatrix}.$$

Diagonale : incertitudes individuelles

- $P_{11} = \mathrm{Var}(p)$: "à quel point je connais la position ?"
- $P_{22} = \mathrm{Var}(v)$: "à quel point je connais la vitesse ?"

Hors-diagonale : couplage / transfert d'information

- $P_{12} = \mathrm{Cov}(p,v) \neq 0$: erreur sur p et erreur sur v varient ensemble : si p est surestimée, v a tendance à l'être aussi (ou l'inverse).
- En navigation : la dynamique crée naturellement des corrélations (propagation d'erreur).
- **Conséquence Kalman :** une mesure de p peut réduire l'incertitude sur v (et inversement) si $P_{12} \neq 0$.
  Ignorer les hors-diagonales revient à perdre de l'information.

Loi normale multivariée : une forme géométrique

$$\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{P})$$

Les niveaux de densité constante vérifient :

$$(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{P}^{-1} (\mathbf{x} - \boldsymbol{\mu}) = \text{constante}.$$

Interprétation : ce sont des **ellipsoïdes** centrés en $\boldsymbol{\mu}$.

- Orientation = vecteurs propres de $\boldsymbol{P}$,
- longueurs des axes = proportionnelles à $\sqrt{\lambda_i}$ (valeurs propres).

Message : P n'est pas juste une "erreur" : c'est une **forme** (taille + orientation) de l'incertitude.

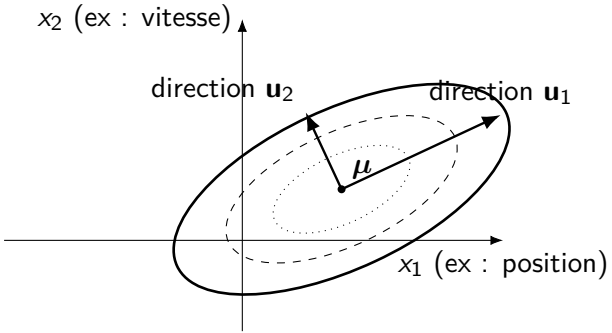
- **Symétrie et positivité**
  La matrice de covariance $\boldsymbol{P}$ est toujours :
  - **Symétrique** : $\boldsymbol{P} = \boldsymbol{P}^\top$.
  - **Semi-définie positive** : Pour tout vecteur v, $v^\top \boldsymbol{P} v \geq 0$.

- **Décomposition spectrale**
  Toute matrice de covariance peut être décomposée en :

$$\boldsymbol{P} = \mathbf{R}\mathbf{D}\mathbf{R}^\top,$$

  où :
  - **R** est une matrice de rotation (orthogonale).
  - **D** est une matrice diagonale contenant les **valeurs propres** de $\boldsymbol{P}$.

Schéma : incertitude = ellipse

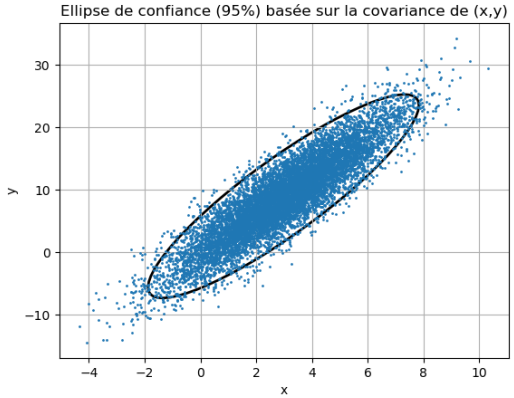


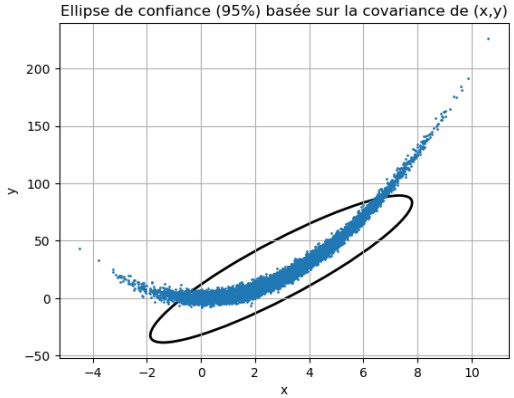
Forme

Ellipse large : forte incertitude
Ellipse inclinée : corrélation ($P_{12} \neq 0$)
Axes $\mathbf{u}_i$: vecteurs propres de P

niveaux de confiance

pointillés via $(x - \mu)^\top P^{-1}(x - \mu) = \text{cste}$


Ellipse de confiance (95%) basée sur la covariance de (x,y)
30
20
10
0
−10
y
−4
−2
0
2
4
6
8
10
x


Ellipse de confiance (95%) basée sur la covariance de (x,y)
200
150
100
50
0
−50
y
−4
−2
0
2
4
6
8
10
x

Pour Kalman : que retient-on ?

Kalman manipule à chaque instant :

$$\text{une moyenne } \boldsymbol{\mu}_k \quad \text{et une covariance } \mathbf{P}_k.$$

Interprétation physique :

- $\boldsymbol{\mu}_k$: l'**état estimé** noté $\hat{\mathbf{x}}_k$ (position, vitesse, etc.).
- $\mathbf{P}_k$: l'**incertitude structurée** (taille + orientation + couplages).
- Le modèle dynamique ne "donne" pas seulement une prédiction : il **déforme/élargit** l'ellipse.
- Une mesure ne "donne" pas seulement une valeur : elle **resserre** l'ellipse.

Bilan : Kalman = **propager** et **corriger** une ellipse d'incertitude.

Sommaire

1. Introduction
2. Rappels statistiques : incertitude et corrélations
3. Estimateurs : du “meilleur linéaire” au gain de Kalman
4. Filtre de Kalman : cadre et modèle (partir de zéro)
5. Interprétation physique et géométrique
6. Extended Kalman Filter (EKF)

Objectif : comprendre la racine statistique de Kalman

- Partir d'un problème **statique** : estimer un état **x** à partir d'une mesure **y**.
- Définir un critère : minimiser l'**erreur quadratique moyenne** (MSE).
- En se limitant aux estimateurs **linéaires/affines** : obtenir le **LMMSE**.
- Lire le résultat comme une **projection orthogonale** (principe d'orthogonalité).
- Faire le pont direct vers la **structure du gain de Kalman**.

Problème d'estimation (statique) : modèle de mesure

Modèle linéaire bruité (cas courant en capteurs) :

$$\mathbf{y} = H\mathbf{x} + \mathbf{v}, \qquad \mathbb{E}[\mathbf{v}] = \mathbf{0}, \qquad \mathrm{Cov}(\mathbf{v}) = \mathbf{R}.$$

- $\mathbf{x} \in \mathbb{R}^n$: état à estimer ; $\mathbf{y} \in \mathbb{R}^m$: mesure ; $H \in \mathbb{R}^{m \times n}$.
- $\mathbf{R} \in \mathbb{R}^{m \times m}$: incertitude (bruit) du capteur.
- Cas scalaire : $m = 1 \Rightarrow \mathbf{R} = R \in \mathbb{R}$.

On cherche un estimateur $\hat{\mathbf{x}} = g(\mathbf{y})$ minimisant :

$$\hat{\mathbf{x}} = \arg\min_{g} \ \mathbb{E}\left[\|g(\mathbf{y}) - \mathbf{x}\|^2\right].$$

Fait clé : si $(\mathbf{x}, \mathbf{y})$ sont **jointement gaussiens**, l'estimateur optimal (MMSE) est **affine** en $\mathbf{y}$.

MSE — Mean Squared Error (critère de performance)

Définition (scalaire) pour un estimateur $\hat{x}$ de x :

$$\mathrm{MSE} = \mathbb{E}\big[(x - \hat{x})^2\big].$$

Définition (vectorielle) pour $\hat{\mathbf{x}}$ de $\mathbf{x}$:

$$\mathbf{P} = \mathbb{E}\big[(\mathbf{x} - \hat{\mathbf{x}})(\mathbf{x} - \hat{\mathbf{x}})^\top\big].$$

Interprétation physique

La MSE mesure l'**énergie moyenne** de l'erreur d'estimation. Dans Kalman, $\mathbf{P}_k$ est précisément la MSE matricielle de l'état au temps k.

MSE — Biais / variance : pourquoi minimiser la MSE ?

Pour un estimateur (scalaire) éventuellement biaisé :

$$\mathrm{MSE} = \underbrace{\mathrm{Var}(\hat{x})}_{\text{dispersion}} + \underbrace{\mathrm{Biais}(\hat{x})^2}_{\text{erreur systématique}} .$$

- **Variance** : sensibilité au bruit (fluctuations aléatoires).
- **Biais** : erreur systématique (modèle incomplet, biais capteur non modélisé, etc.).

Lecture pratique

Minimiser la MSE, c'est chercher un compromis entre **stabilité** (variance faible) et **justesse** (biais faible).

Famille des estimateurs linéaires (affines)

On se limite à des estimateurs affines :

$$\hat{\mathbf{x}} = K\mathbf{y} + \mathbf{b}, \qquad K \in \mathbb{R}^{n \times m},\ \mathbf{b} \in \mathbb{R}^n.$$

Deux objectifs "physiques"

- **Pas de biais** : l'estimation n'est pas systématiquement trop haute/trop basse.
- **Erreur minimale** : on exploite au mieux l'information contenue dans la mesure.

Lecture géométrique : choisir $(K, \mathbf{b})$ revient à choisir une transformation affine qui projette au mieux l'information de $\mathbf{y}$ vers $\mathbf{x}$.

Condition “sans biais” (centrage)

Condition de non-biais au sens de l'espérance :

$$\mathbb{E}[\hat{\mathbf{x}}] = \mathbb{E}[\mathbf{x}].$$

Avec $\hat{\mathbf{x}} = K\mathbf{y} + \mathbf{b}$ et $\boldsymbol{\mu}_x = \mathbb{E}[\mathbf{x}]$, $\boldsymbol{\mu}_y = \mathbb{E}[\mathbf{y}]$:

$$K\boldsymbol{\mu}_y + \mathbf{b} = \boldsymbol{\mu}_x \quad \Rightarrow \quad \mathbf{b} = \boldsymbol{\mu}_x - K\boldsymbol{\mu}_y.$$

Conséquence pratique

En travaillant sur les variables centrées $\tilde{\mathbf{x}} = \mathbf{x} - \boldsymbol{\mu}_x$, $\tilde{\mathbf{y}} = \mathbf{y} - \boldsymbol{\mu}_y$, on peut écrire l'estimateur sous la forme :

$$\hat{\tilde{\mathbf{x}}} = K\tilde{\mathbf{y}}.$$

Principe d'orthogonalité (clé du LMMSE)

On définit l'erreur d'estimation $\varepsilon = \mathbf{x} - \hat{\mathbf{x}}$.

Principe (LMMSE : Linear Minimum Mean Squared Error)

Le meilleur estimateur linéaire au sens MSE vérifie :

$$\mathbb{E}\left[\varepsilon\, \tilde{\mathbf{y}}^{\top}\right] = 0 \quad \Longleftrightarrow \quad \varepsilon \perp \text{l'espace vectoriel engendré par } (\tilde{\mathbf{y}}).$$

Interprétation physique :

- Si l'erreur est **corrélée** à la mesure, alors la mesure contient encore de l'information exploitable.
- À l'optimum :
  - l'erreur est orthogonale à tout vecteur construit à partir de la mesure
  - l'erreur n'est plus corrélée à la mesure,
  - il n'y a plus d'information exploitable dans $\tilde{\mathbf{y}}$
  - l'innovation (linéaire) ne contient plus d'info pour réduire la MSE.

Résultat : gain LMMSE (forme covariance)

Notations (moments d'ordre 2) :

$$P_{xy} = \mathbb{E}[\tilde{\mathbf{x}}\tilde{\mathbf{y}}^\top], \qquad P_{yy} = \mathbb{E}[\tilde{\mathbf{y}}\tilde{\mathbf{y}}^\top].$$

Gain optimal (meilleur estimateur linéaire)

$$\boxed{K^\star = P_{xy}\, P_{yy}^{-1}}$$

Interprétation : $K^\star$ est un rapport de corrélations : il dit comment **y** porte de l'information sur **x**.

Application au modèle $\mathbf{y} = H\mathbf{x} + \mathbf{v}$

Si $\mathbf{v}$ est indépendant de $\mathbf{x}$:

$$P_{xy} = P\,H^\top, \qquad P_{yy} = HPH^\top + R,$$

où

$$P = \mathrm{Cov}(\mathbf{x}), \qquad R = \mathrm{Cov}(\mathbf{v}).$$

Forme "gain de Kalman" (statique)

$$\boxed{K^\star = P\,H^\top (HPH^\top + R)^{-1}}$$

Lecture : on pondère la correction selon la confiance relative (incertitude état vs capteur).

Lecture “avant / après” : effet du capteur sur l’incertitude

Avec l’estimateur LMMSE :

$$P_\varepsilon = \mathrm{Cov}(\mathbf{x} - \hat{\mathbf{x}}) = P - PH^\top (HPH^\top + R)^{-1} HP.$$

Interprétation physique (fusion)

- Si R est grand (capteur bruité) : $(HPH^\top + R)^{-1}$ petit $\Rightarrow$ gain faible.
- Si P est grand (état très incertain) : le gain augmente $\Rightarrow$ on **écoute** davantage la mesure.
- Le terme $(HPH^\top + R)$ est l’incertitude **dans l’espace mesure**.

Pont vers Kalman : innovation et mise à jour (une mesure)

On suppose une estimation a priori (prédite) :

$$\hat{\mathbf{x}}^{-} \text{ ou } \hat{\mathbf{x}}_{k|k-1}, \qquad P^{-} \text{ ou } P_{k|k-1}.$$

On mesure $\mathbf{y}$ et on définit l'**innovation** :

$$\mathbf{r} = \mathbf{y} - H\hat{\mathbf{x}}^{-}.$$

Mise à jour (structure Kalman)

$$K = P^{-}H^{\top}(HP^{-}H^{\top} + R)^{-1}, \qquad \hat{\mathbf{x}} = \hat{\mathbf{x}}^{-} + K\,\mathbf{r}, \qquad P = (I - KH)P^{-}.$$

Message : Kalman répétera cette logique à chaque instant après une étape de prédiction dynamique.

À retenir (avant de passer au cadre dynamique)

- La performance se mesure naturellement par la **MSE** (scalaire) ou la **covariance d'erreur** P (vectorielle).
- Le LMMSE est une **projection orthogonale** : erreur orthogonale à l'espace des mesures.
- Le gain optimal s'écrit :

$$K^\star = P_{xy} P_{yy}^{-1} = PH^\top (HPH^\top + R)^{-1}.$$

- La forme "Kalman" apparaît déjà en **statique** (une mesure) via l'innovation **r**.

Prochaine étape : gestion de la dynamique $\Rightarrow (F, Q)$.

Sommaire

1. Introduction
2. Rappels statistiques : incertitude et corrélations
3. Estimateurs : du “meilleur linéaire” au gain de Kalman
4. Filtre de Kalman : cadre et modèle (partir de zéro)
5. Interprétation physique et géométrique
6. Extended Kalman Filter (EKF)

Objectif du filtre

- Les capteurs mesurent avec du bruit : GPS, lidar, caméra, IMU, radar...
- Les modèles physiques sont imparfaits : frottements, perturbations, approximations...
- Une estimation « au fil de l'eau » doit être :
  - **récursive** (temps réel, pas besoin de stocker tout l'historique),
  - **robuste** (gère bruit + incertitudes),
  - **quantifiée** (donne une incertitude).

Idée centrale

Kalman combine **modèle** + **mesure** + **incertitudes** pour produire une estimation **et** information sur l'erreur d'approximation avec la covariance de l'erreur.

Le problème : estimer un état qui évolue dans le temps

État (state) vs mesure (measurement)

- x_k : **état** au temps discret k (quantité cachée : position, vitesse, orientation...)
- y_k : **mesure** observée au temps k (capteur)

But

À chaque instant k, produire :

$$\hat{x}_{k|k} \quad \text{et une incertitude} \quad P_{k|k}.$$

- $\hat{x}_{k|k}$: estimation de x_k en utilisant les mesures jusqu'à k.
- $P_{k|k}$: covariance de l'erreur d'estimation (quantification de l'incertitude).

Modèle d'état (linéaire) : deux équations

Équation d'évolution (dynamique linéaire)

$$x_k = F\,x_{k-1} + G\,u_{k-1} + w_{k-1}$$

Équation de mesure (capteur)

$$y_k = H\,x_k + v_k$$

- u_{k-1} : entrée/commande connue (optionnelle) ; F, G, H : matrices du modèle
- w_{k-1} : **bruit de processus** (incertitude modèle)
- v_k : **bruit de mesure** (incertitude capteur)

Hypothèses probabilistes (le minimum à poser)

Hypothèses standard du Kalman linéaire

$$w_k \sim \mathcal{N}(0, Q), \qquad v_k \sim \mathcal{N}(0, R)$$

$$w_k \perp v_j, \quad w_k \perp x_0, \quad v_k \perp x_0 \quad (\forall k, j)$$

- Q : covariance du bruit de processus (**modèle**)
- R : covariance du bruit de mesure (**capteur**)

Interprétation physique de Q et R

R : bruit de mesure

- grand R : capteur peu fiable
- petit R : capteur précis

Q : bruit de processus

- grand Q : modèle incertain / perturbé
- petit Q : modèle très fiable

Conséquence qualitative

- si $R \uparrow$: on fait **moins confiance** à la mesure
- si $Q \uparrow$: on fait **moins confiance** au modèle

À retenir

Kalman est un **compromis** réglé par Q et R.

Ce que Kalman va produire à chaque pas

Deux sorties

$\hat{x}_{k|k}$ (meilleure estimation) $P_{k|k}$ (incertitude associée)

- On ne veut pas seulement un nombre : on veut aussi **une confiance**.
- Cette confiance permet :
  - de fusionner plusieurs capteurs,
  - de détecter des anomalies (innovation anormale),
  - de régler automatiquement le poids modèle/mesure.

Vocabulaire

a priori : $\hat{x}_{k|k-1}$, $P_{k|k-1}$ **a posteriori** : $\hat{x}_{k|k}$, $P_{k|k}$

Innovation : « information nouvelle » apportée par la mesure

Définition

$$r_k = y_k - H\,\hat{x}_{k|k-1}$$

- r_k compare **ce que le capteur observe** à **ce que le modèle prédit**.
- Si r_k est grand : surprise $\Rightarrow$ correction importante (selon R).
- Si r_k est petit : mesure cohérente $\Rightarrow$ correction faible.

Annonce

La mise à jour Kalman aura la forme :

$$\hat{x}_{k|k} = \hat{x}_{k|k-1} + K_k\, r_k.$$

Bilan - A savoir

- Vous savez écrire le modèle :

$$x_k = Fx_{k-1} + Gu_{k-1} + w_{k-1}, \qquad y_k = Hx_k + v_k.$$

- Vous savez ce que représentent Q et R (et leur effet qualitatif).
- Vous savez ce qu'est l'innovation :

$$r_k = y_k - H\hat{x}_{k|k-1}.$$

Algo complet - Étape 1 : Prédiction

État prédit

$$\hat{\mathbf{x}}_k^- = F\,\hat{\mathbf{x}}_{k-1} + G\,\mathbf{u}_{k-1}$$

Covariance prédite

$$P_k^- = FP_{k-1}F^\top + Q$$

Interprétation

On propage l'état et son incertitude via le modèle dynamique.

Algo complet - Étape 2 : Correction

Innovation

$$\mathbf{r}_k = \mathbf{y}_k - H\hat{\mathbf{x}}_k^-$$

Covariance de l'innovation

$$S_k = HP_k^- H^\top + R$$

Gain de Kalman

$$K_k = P_k^- H^\top S_k^{-1}$$

Mise à jour

$$\hat{\mathbf{x}}_k = \hat{\mathbf{x}}_k^- + K_k \mathbf{r}_k$$

$$P_k = (I - K_k H) P_k^-$$

Exemple Kalman linéaire : position + vitesse 1D (vitesse constante)

Un mobile se déplace en ligne droite. On mesure uniquement sa position.

- Quel est l'état minimal pour modéliser ce système ?
- Construire la dynamique F
- Construire H et justifier sa dimension
- Que signifie concrètement l'équation $\hat{\mathbf{x}}_k^- = F\,\hat{\mathbf{x}}_{k-1}$?
- Que représente Q dans l'équation $P_k^- = FP_{k-1}F^\top + Q$
- Quelle est la dimension de K
- Pourquoi la vitesse est-elle corrigée alors qu'on ne la mesure pas ?
- Que signifie physiquement l'innovation ?
- Bonus : Si $P^- = \begin{pmatrix} 4 & 2 \\ 2 & 1 \end{pmatrix}$ et $R = 1$. Calculer K.

Sommaire

1. Introduction
2. Rappels statistiques : incertitude et corrélations
3. Estimateurs : du “meilleur linéaire” au gain de Kalman
4. Filtre de Kalman : cadre et modèle (partir de zéro)
5. Interprétation physique et géométrique
6. Extended Kalman Filter (EKF)

Rappel : structure complète du filtre de Kalman

Prédiction

$$\hat{\mathbf{x}}_k^- = F\hat{\mathbf{x}}_{k-1} \qquad P_k^- = FP_{k-1}F^\top + Q$$

Correction

$$K_k = P_k^- H^\top (HP_k^- H^\top + R)^{-1}$$

$$\mathbf{r}_k = \mathbf{y}_k - H\hat{\mathbf{x}}_k^-$$

$$\hat{\mathbf{x}}_k = \hat{\mathbf{x}}_k^- + K_k\mathbf{r}_k$$

$$P_k = (I - K_k H)P_k^-$$

Interprétation physique des matrices

F : **dynamique du système**

- Transporte l'état dans le temps
- Déforme l'ellipse d'incertitude

Q : **incertitude du modèle**

- Accélérations non modélisées
- Erreurs IMU
- Approximation du modèle

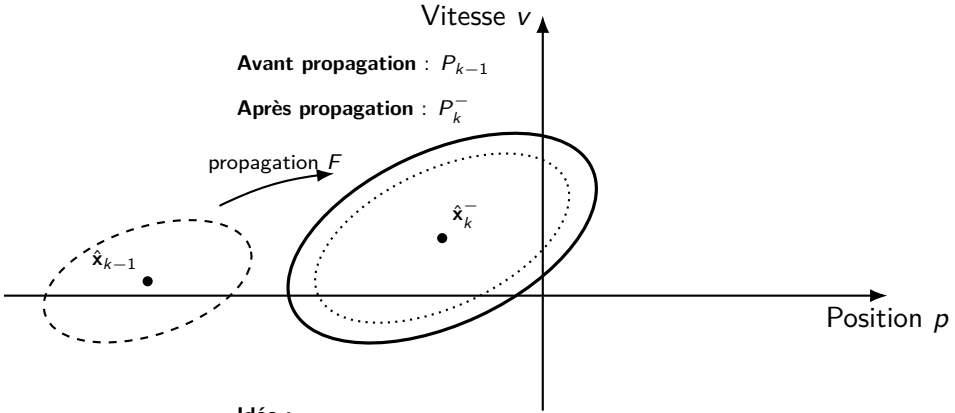
H : **modèle de mesure**

- Projection de l'état vers l'espace mesure

R : **incertitude du capteur**

- Bruit GPS, LiDAR, capteur

Visualisation : P_k^- (prédiction) et inflation par Q



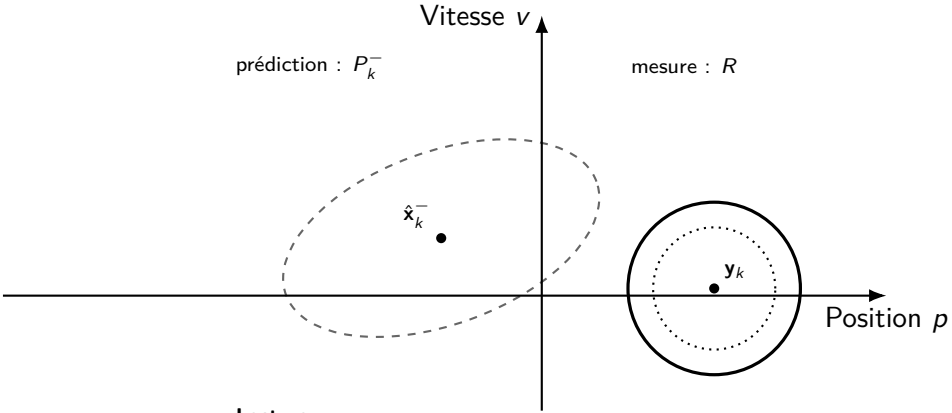
Idée :

F transporte et déforme l'ellipse

Q l'**agrandit** (incertitude modèle/IMU)

$$P_k^- = FP_{k-1}F^\top + Q$$

Visualisation : R (incertitude de mesure) et S_k



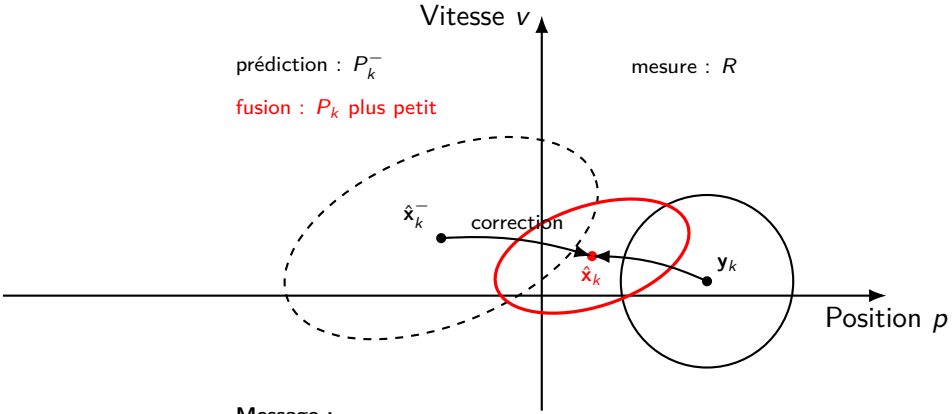
Lecture :

petit $R \Rightarrow$ mesure fiable

grand $R \Rightarrow$ mesure bruitée

$$S_k = HP_k^- H^\top + R \qquad \text{(incertitude dans l'espace mesure)}$$

Fusion géométrique : de P_k^- et R vers P_k



Message :

la correction "resserre" l'incertitude

(intersection probabiliste)

$$\hat{\mathbf{x}}_k = \hat{\mathbf{x}}_k^- + K_k \mathbf{r}_k \qquad P_k = (I - K_k H) P_k^-$$

Sommaire

1. Introduction
2. Rappels statistiques : incertitude et corrélations
3. Estimateurs : du “meilleur linéaire” au gain de Kalman
4. Filtre de Kalman : cadre et modèle (partir de zéro)
5. Interprétation physique et géométrique
6. Extended Kalman Filter (EKF)

Pourquoi l'EKF ?

Le filtre de Kalman classique suppose :

$$x_k = Fx_{k-1} + Gu_{k-1} + w_{k-1} \qquad y_k = Hx_k + v_k$$

Problème

Dans beaucoup de systèmes réels :

- la dynamique est non linéaire,
- les mesures sont non linéaires.

Exemples

- Robot mobile (cinématique non linéaire)
- Mesure GPS en coordonnées polaires
- Orientation (angles, quaternions)

Modèle non linéaire général

Équations d'état

$$x_k = f(x_{k-1}, u_{k-1}) + w_{k-1}$$

$$y_k = h(x_k) + v_k$$

- $f(\cdot)$: dynamique non linéaire
- $h(\cdot)$: fonction de mesure non linéaire
- $w_k \sim \mathcal{N}(0, Q)$
- $v_k \sim \mathcal{N}(0, R)$

Idée centrale de l'EKF

Principe

Linéariser localement autour de l'estimation courante.

$$f(x) \approx f(\hat{x}) + F_k(x - \hat{x}) \qquad h(x) \approx h(\hat{x}) + H_k(x - \hat{x})$$

Jacobiennes*

$$F_k = \left.\frac{\partial f}{\partial \mathbf{x}}\right|_{\hat{\mathbf{x}}_{k-1}, \mathbf{u}_{k-1}} \qquad H_k = \left.\frac{\partial h}{\partial \mathbf{x}}\right|_{\hat{\mathbf{x}}_k^-}$$

- F_k joue le rôle de F
- H_k joue le rôle de H
- Elles dépendent du point de linéarisation

Rappels : matrice Jacobienne

Soit $F : \mathbb{R}^n \to \mathbb{R}^m$.

$$F : \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} \longmapsto \begin{pmatrix} f_1(x_1, \ldots, x_n) \\ \vdots \\ f_m(x_1, \ldots, x_n) \end{pmatrix}.$$

Matrice jacobienne de F au point M :

$$J_F(M) = \begin{pmatrix} \frac{\partial f_1}{\partial x_1} & \cdots & \frac{\partial f_1}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial f_m}{\partial x_1} & \cdots & \frac{\partial f_m}{\partial x_n} \end{pmatrix}.$$

Étape 1 — Prédiction EKF

Prédiction de l'état

$$\hat{\mathbf{x}}_{k|k-1} = f(\hat{\mathbf{x}}_{k-1|k-1}, \mathbf{u}_{k-1})$$

Propagation de la covariance

$$P_{k|k-1} = F_k P_{k-1|k-1} F_k^\top + Q$$

- Même structure que le KF linéaire.
- Mais F_k dépend de l'état courant.

Étape 2 — Mise à jour EKF

Innovation

$$\mathbf{r}_k = \mathbf{y}_k - h(\hat{\mathbf{x}}_{k|k-1})$$

Covariance de l'innovation

$$S_k = H_k P_{k|k-1} H_k^\top + R$$

Gain de Kalman

$$K_k = P_{k|k-1} H_k^\top S_k^{-1}$$

Correction

$$\hat{\mathbf{x}}_{k|k} = \hat{\mathbf{x}}_{k|k-1} + K_k \mathbf{r}_k$$

$$P_{k|k} = (I - K_k H_k) P_{k|k-1}$$

Algorithme EKF

version courte

Prédiction

$$\hat{\mathbf{x}}_k^- = f(\hat{\mathbf{x}}_{k-1}, \mathbf{u}_{k-1})$$

$$P_k^- = F_k P_{k-1} F_k^\top + Q$$

Innovation

$$\mathbf{r}_k = \mathbf{y}_k - h(\hat{\mathbf{x}}_k^-)$$

Correction

$$K_k = P_k^- H_k^\top (H_k P_k^- H_k^\top + R)^{-1}$$

$$\hat{\mathbf{x}}_k = \hat{\mathbf{x}}_k^- + K_k \mathbf{r}_k$$

$$P_k = (I - K_k H_k) P_k^-$$

Lecture intuitive de l'EKF

- À chaque instant, on approxime le système par un modèle linéaire local.
- On applique les équations du Kalman linéaire.
- On répète au pas suivant.

Important

L'EKF est une approximation locale.

Exemple : D'après le TD3, exercice 4 : Mise sous forme d'état (robot mobile plan)

Vecteur d'état

$$\mathbf{x}(t) = \begin{pmatrix} x(t) \\ y(t) \\ \theta(t) \end{pmatrix}.$$

Grandeurs commandées / mesurées

- **vitesse longitudinale** $v(t)$
- **vitesse angulaire** $\omega(t)$ autour de l'axe vertical.

$$\mathbf{u}(t) = \begin{pmatrix} v(t) \\ \omega(t) \end{pmatrix}.$$

Equations d'état finales

Modèle cinématique plan

$$\begin{cases} \dot{x}(t) = v(t)\cos\theta(t), \\ \dot{y}(t) = v(t)\sin\theta(t), \\ \dot{\theta}(t) = \omega(t). \end{cases}$$

Ajout : mesures

On supposera qu'un GPS mesure la position

$$\mathbf{y}_k = \begin{pmatrix} x_k \\ y_k \end{pmatrix} + \mathbf{v}_k$$

Exemple : D'après le TD3, exercice 4 : Mise sous forme d'état (robot mobile plan)

- Pourquoi EKF ?
- Écrire la fonction $f(\mathbf{x}_k, \mathbf{u}_k)$
- Calculer la Jacobienne dynamique F_k
- Écrire la fonction de mesure $h(\mathbf{x})$
- Calculer la Jacobienne mesure H_k
- Déterminer l'innovation
- Pourquoi θ sera corrigé alors qu'on ne la mesure pas ?