Capteurs

Fusion multi-capteurs

Dr. Hind Laghmara
hind.laghmara@insa-rouen.fr

INSA INSTITUT NATIONAL DES SCIENCES APPLIQUÉES ROUEN NORMANDIE

ISIA3 – 2026



Introduction et objectifs
Comment fusionner?
Qui donne l'heure?
Quelques bases de données
Méthodes de fusion

Introduction et objectifs

Objectifs d'apprentissage de cette séance
Pourquoi?

Objectifs d'apprentissage du cours

- Comprendre les enjeux de la fusion multi-capteurs
- Identifier les différents niveaux de fusion (données, caractéristiques, décisions)
- Maîtriser les problématiques de synchronisation des capteurs
- Analyser et exploiter des bases de données multimodales
- Connaître les principales méthodes de fusion

Pourquoi un cours sur la fusion multi-capteurs ?

Parce qu'un seul capteur ne voit jamais tout.

- Une caméra → riche en information visuelle, mais pas de profondeur directe
- Un lidar → excellente géométrie 3D, mais peu d'information sémantique
- Un GPS → position globale, mais précision limitée

La fusion permet de :

- Expliquer les enjeux de la synchronisation temporelle
- Comparer les approches :
  - Synchronisation matérielle
  - Synchronisation logicielle
- Modéliser les erreurs temporelles
- Mettre en place une stratégie d'horodatage cohérente

Plus d'information + meilleure cohérence = décisions plus intelligentes

Comment fusionner?

Fusion de données

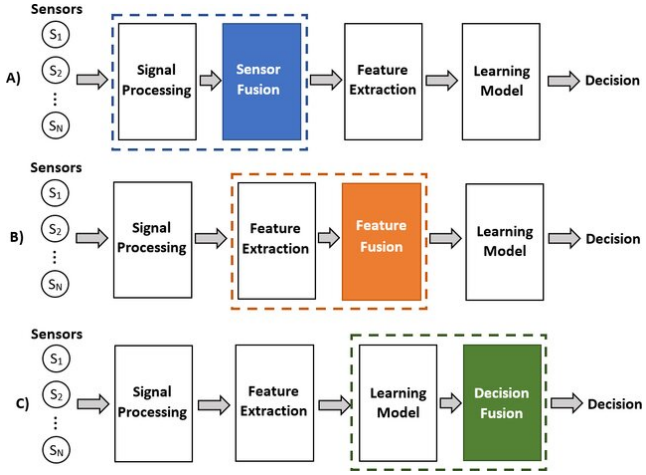
Définition

La fusion de capteurs est un processus qui consiste à combiner des données provenant de capteurs ou de sources (modalités) afin que les informations obtenues présentent moins d'incertitudes ou que ça apporte plus de redandonces et complémentarité.

Différents niveaux

- Niveau données
- Niveau caractérisiques
- Niveau décisions

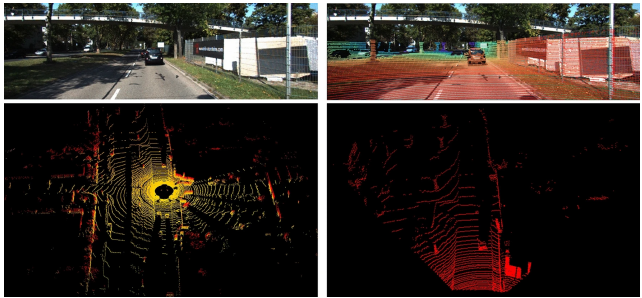
Niveaux de fusion



E. Debie et al., "Multimodal Fusion for Objective Assessment of Cognitive Workload: A Review," IEEE Trans. Cybern., vol. 51, no. 3, pp. 1542–1555, 2021.

Niveaux de fusion: Early

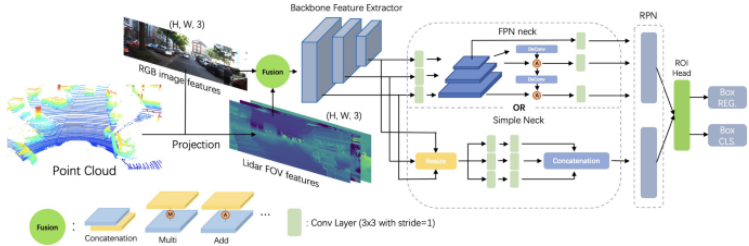
Fusion de données brutes



Wang, L., Huang, Y. LiDAR–camera fusion for road detection using a recurrent conditional random field model. Sci Rep 12, 11320 (2022).

Niveaux de fusion: Middle

Fusion de caractéristiques



Mousa-Pasandi, M., Liu, T., Massoud, Y. et al. RGB-LiDAR fusion for accurate 2D and 3D object detection. Machine Vision and Applications 34, 86 (2023).

Fusion middle : quelles caractéristiques ?

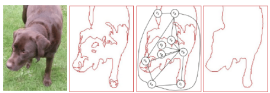
Pour résumer

- Fusion au niveau des **caractéristiques extraites**
- Chaque capteur est traité indépendamment avant fusion

Exemples de caractéristiques

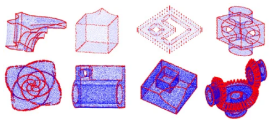
Image (caméra)

- Contours, textures
- Descripteurs (SIFT, ORB)
- Features profondes (CNN)



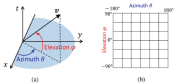
LiDAR

- Points 3D, densité
- Formes géométriques
- Plans, surfaces



IMU / GPS

- Vitesse, accélération
- Orientation
- Position



M. Zand, S. Doraisamy, A. A. Halin and M. R. Mustaffa, "Automatic object segmentation using perceptual grouping of regions with contextual constraints,"

Tran T, Ali S, Laurendeau D (2013). Automatic Sharp Feature Extraction from Point Clouds with Optimal Neighborhood Size.

Fusion middle : quelles caractéristiques ?

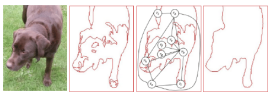
Pour résumer

- Fusion au niveau des **caractéristiques extraites**
- Chaque capteur est traité indépendamment avant fusion

Exemples de caractéristiques

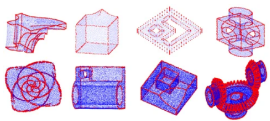
Image (caméra)

- Contours, textures
- Descripteurs (SIFT, ORB)
- Features profondes (CNN)



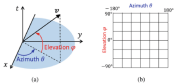
LiDAR

- Points 3D, densité
- Formes géométriques
- Plans, surfaces



IMU / GPS

- Vitesse, accélération
- Orientation
- Position



M. Zand, S. Doraisamy, A. A. Halin and M. R. Mustaffa, "Automatic object segmentation using perceptual grouping of regions with contextual constraints,"
Tran T, Ali S, Laurendeau D (2013). Automatic Sharp Feature Extraction from Point Clouds with Optimal Neighborhood Size.

Niveaux de fusion: Late

Fusion de décisions

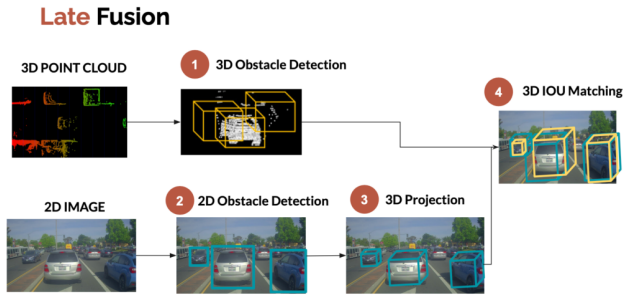


Image Source

Qui donne l'heure?

Synchronisation matérielle
Synchronisation logicielle

Synchronisation des capteurs en fusion de données

Pourquoi synchroniser ?

- Associer correctement des mesures issues de capteurs différents
- Garantir la cohérence temporelle des données fusionnées
- Éviter des erreurs d'estimation (décalage image–lidar, biais inertiel, etc.)

Problème fondamental :

- Capteurs avec fréquences différentes (ex : caméra 30 Hz, lidar 10 Hz, IMU 200 Hz)
- Horloges internes différentes
- Latences de communication variables

Stratégies de synchronisation :

- **Trigger matériel** (signal commun, PPS, PTP)
- **Horodatage logiciel** (timestamp système commun)
- **Interpolation temporelle** et alignement a posteriori

Objectif : représenter l'état du système au même instant t

Panorama des méthodes de synchronisation

Problématique :

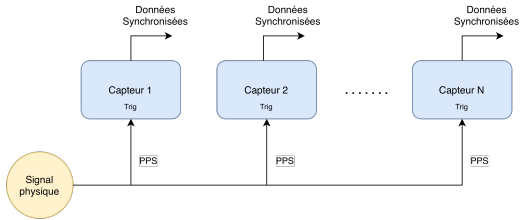
- Capteurs hétérogènes (caméra, lidar, IMU, GPS)
- Fréquences d'acquisition différentes
- Horloges indépendantes et dérive temporelle

Trois grandes approches :

1. Synchronisation matérielle (hardware-based)
2. Synchronisation par horodatage logiciel
3. Synchronisation a posteriori (post-traitement)

Le choix dépend de la précision requise et des contraintes système

Synchronisation matérielle



Principe :

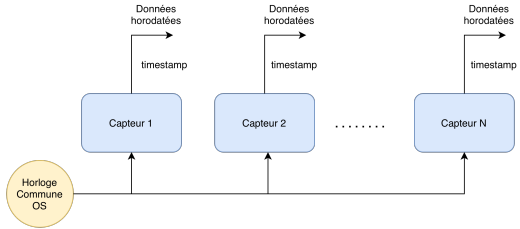
- Utilisation d'un signal physique commun
- Front de déclenchement (Trigger IN/OUT)
- Signal PPS (Pulse Per Second)
- Horloge distribuée (PTP – IEEE 1588)

Avantages :

- Très faible jitter (µs à ns)
- Pas dépendant du système d'exploitation
- Haute cohérence inter-capteurs

Jitter/Gigue: la différence de délai de transmission de bout en bout entre des paquets choisis dans un même flux de paquets

Synchronisation par horodatage logiciel



Principe :

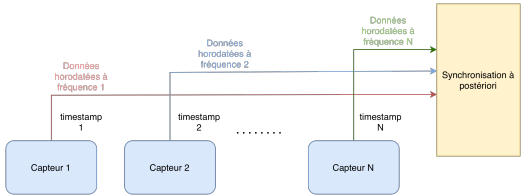
- Chaque mesure reçoit un timestamp système
- Horloge commune (monotonic clock / system clock)
- Fusion basée sur l'alignement temporel

Précision typique : Millisecondes à dizaines de millisecondes
Avantage majeur : simplicité et faible coût

Sources d'erreur :

- Latence d'acquisition
- Jitter OS (ordonnancement)
- Dérive de l'horloge interne

Synchronisation a posteriori



Principe :

- Estimation d'un offset temporel entre flux
- Corrélation de signaux communs
- Interpolation ou recalage dynamique

Exemples :

- Alignement image–IMU par optimisation
- Recalage lidar–caméra via mouvement commun

Avantages :

- Pas besoin de matériel spécifique
- Applicable a posteriori

Limite : dépend fortement de la qualité des données

Comparaison des méthodes

Critère	Matérielle	Logicielle	Post
Précision	Très élevée	Moyenne	Variable
Jitter	Très faible	Modéré	Estimé
Coût matériel	Élevé	Faible	Faible
Complexité	Élevée	Faible	Moyenne
Temps réel	Oui	Oui	Non (souvent)

Recommandations :

- Robotique critique → Synchronisation matérielle
- Prototypage / systèmes embarqués simples → Logicielle
- Données enregistrées / recherche → Post-traitement

Quelques bases de données

Bases de données multimodales

Définition

Un dataset multimodal est un ensemble de données qui contient plusieurs types de modalités ou de formats de données (images, nuage de données, texte, audio, etc.).

Applications

- Reconnaissance d'images et description automatique (vision + texte)
- Assistants vocaux intelligents (audio + texte)
- Véhicules autonomes (caméras, LiDAR, radar, GPS)
- Analyse des émotions (expression faciale + voix + texte)
- Génération de texte à partir d'images (image captioning)
- Détection de fake news (texte + image + contexte social)
- Jeux vidéo et réalité virtuelle (audio + visuel + interaction utilisateur)

Source: INNOVATIA

Comment choisir une base de données multimodale?

Diversité et richesse des modalités

Comment choisir une base de données multimodale?

Qualité des annotations

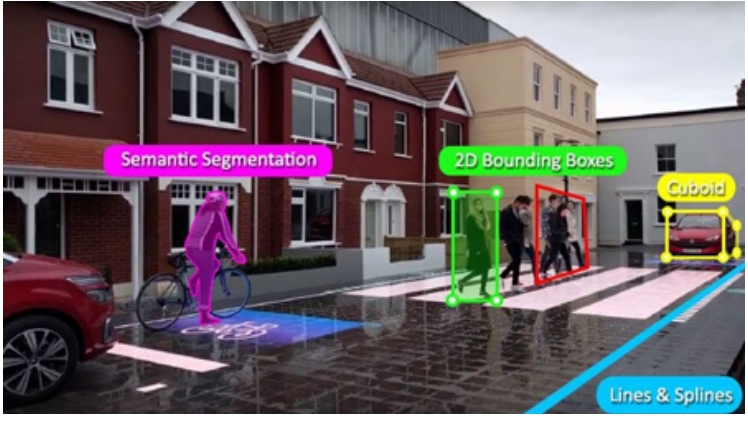


Image source

Comment choisir une base de données multimodale?

Volume et taille du dataset

Dataset	Modalités	Volume	Échelle
nuScenes	Caméra, LiDAR, radar, GPS/IMU	1000 scènes, 1.4M images	∼1.4M annotations, 390k LiDAR
MUSES	Caméra, LiDAR, radar, event cam, IMU	∼2500 images	Multi-capteurs, incertitude
DELIVER	RGB, profondeur, thermique	∼100k images	Conditions dégradées
ZOD	Caméra, LiDAR, radar	∼100k images	Longue durée, multi-pays

KITTI Dataset

Contexte

- Dataset de référence pour la **conduite autonome**
- Développé par **KIT & Toyota**

Données multimodales

- Caméras (images stéréo)
- LiDAR (3D)
- GPS / IMU (localisation)

Applications

- Détection d'objets
- Estimation de profondeur
- SLAM / localisation
- Tracking



Exemple : fusion caméra + LiDAR

Points clés

- Données réelles (urbain, route)
- Annotations 2D/3D
- Benchmark standard

Autres datasets multimodaux

nuScenes

- Conduite autonome
- Caméra, LiDAR, radar
- Annotations 3D
- Détection, tracking

DELIVER

- Environnements difficiles
- RGB, profondeur, thermique
- Pluie, nuit, brouillard
- Robustesse

MUSES

- Scènes urbaines
- Caméra, LiDAR, radar
- Données réalistes
- Fusion multi-capteurs

Méthodes de fusion

Propriétés de la fusion
Modèle basé sur les probabilités
Modèle basé sur les possibilités
Modèle basé sur les croyances

Notions clés en fusion de données

Précision

- Qualité de la mesure
- Faible dispersion des valeurs
- Dépend du capteur
- Plus la variance est faible, plus la mesure est précise

Incertitude

- Manque d'information sur l'état réel
- Liée au bruit ou à l'ignorance
- Modélisée par des distributions (proba, possibilité…)
- Reflète le doute

Conflit

- Désaccord entre sources
- Informations contradictoires
- Mesurable (ex : divergence)
- Indique un problème de cohérence

Principe de base

Idée clé

- Représenter l'information sous forme de probabilités
- Combiner les distributions issues de différentes sources

Fusion de deux observations z_1 et z_2 :

$$P(x \mid z_1, z_2)$$

Hypothèse d'indépendance conditionnelle :

$$P(x \mid z_1, z_2) \propto \frac{P(z_1 \mid x)\, P(z_2 \mid x)\, P(x)}{P(z_1, z_2)}$$

Théorème de Bayes

Formule centrale

$$P(x \mid z) = \frac{P(z \mid x) \cdot P(x)}{P(z)}$$

Interprétation

- $P(x)$: connaissance a priori
- $P(z \mid x)$: modèle d'observation (vraisemblance)
- $P(x \mid z)$: estimation mise à jour

Fusion = mise à jour successive

$$P(x \mid z_1, z_2) \Rightarrow \text{mise à jour bayésienne}$$

Exemple : fusion de capteurs

Problème

- Estimer la position d'un objet
- Capteur 1 : précis mais bruité
- Capteur 2 : moins précis mais stable

Idée

- Chaque capteur fournit une distribution de probabilité
- La fusion combine ces distributions

Résultat : estimation plus fiable

Fusion gaussienne

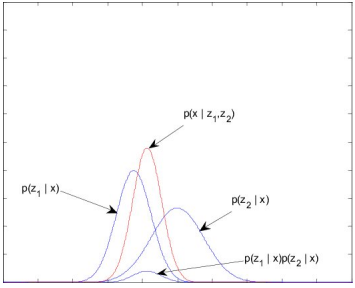
Hypothèse

- Les observations suivent des lois normales

Fusion de deux estimations :

$$\mu = \frac{\sigma_2^2 \mu_1 + \sigma_1^2 \mu_2}{\sigma_1^2 + \sigma_2^2}$$

$$\sigma^2 = \frac{\sigma_1^2 \sigma_2^2}{\sigma_1^2 + \sigma_2^2}$$



Interprétation

- Plus un capteur est précis $\Rightarrow$ plus il influence le résultat

Méthodes avancées

- Filtre de Kalman
- Filtre de Kalman étendu (EKF)
- Filtre particulaire
- Réseaux bayésiens

Objectif

- Gérer des systèmes dynamiques et non linéaires

Exemple numérique : détection de conflit

Problème

- Variable: $x \in \{Objet, Pas\ d'objet\}$
- Deux capteurs donnent des informations contradictoires

Capteur 1 (caméra)

- $P(x = Objet \mid z_1) = 0.9$

Capteur 2 (LiDAR)

- $P(x = Objet \mid z_2) = 0.2$

Fusion naïve (Bayes)

$$P(x \mid z_1, z_2) \propto \frac{P(z_1 \mid x)\, P(z_2 \mid x)\, P(x)}{P(z_1, z_2)}$$

Interprétation

- Les probabilités sont très différentes $\Rightarrow$ **conflit entre capteurs**
- La fusion produit une probabilité intermédiaire
- Le conflit est **quantifiable** (écart entre distributions)

Cas limites en fusion probabiliste

On considère $x \in \{\text{Objet}, \text{Pas d'objet}\}$

$$P(\text{Objet} \mid z_1, z_2) = \frac{P_1 P_2}{P_1 P_2 + (1 - P_1)(1 - P_2)}$$

Cas	P_1	P_2	$P(\text{Objet} \mid z_1, z_2)$
Accord fort	0.99	0.99	0.9999
Conflit total	0.99	0.01	0.5
Capteur neutre	0.8	0.5	0.8
Accord absence	0.01	0.01	≈ 0.0001

Lecture rapide

- Accord $\Rightarrow$ confiance renforcée
- Conflit $\Rightarrow$ incertitude maximale
- Capteur neutre $\Rightarrow$ aucun impact

Fusion de données : pourquoi les possibilités ?

Limites des probabilités

- Nécessitent beaucoup d'informations
- Difficiles à définir en cas d'incertitude forte
- Peu adaptées à l'ignorance

Alternative : théorie des possibilités

- Représente l'incertitude et l'imprécision
- Adaptée aux informations partielles
- Simple et flexible

Théorie des possibilités

Distribution de possibilité

$$\pi(x) \in [0, 1]$$

Mesures associées

- Possibilité : $\Pi(A) = \sup_{x \in A} \pi(x)$
- Nécessité : $N(A) = 1 - \Pi(A^c)$

Interprétation

- $\Pi(A) = 1$: totalement possible
- $N(A) = 1$: certain

Fusion de données possibiliste

Principe

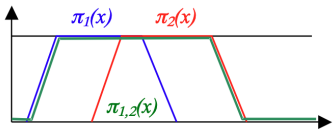
- Combiner plusieurs distributions de possibilité

Fusion conjonctive (intersection)

$$\pi(x) = \min\left(\pi_1(x), \pi_2(x)\right)$$

Fusion disjonctive (union)

$$\pi(x) = \max\left(\pi_1(x), \pi_2(x)\right)$$



Idée

- min : consensus (strict)
- max : tolérance (incertitude)

Exemple numérique

On considère $x \in \{\text{Objet}, \text{Pas d'objet}\}$

Capteur 1

$$\pi_1(\text{Objet}) = 0.9, \quad \pi_1(\text{Pas}) = 0.2$$

Capteur 2

$$\pi_2(\text{Objet}) = 0.4, \quad \pi_2(\text{Pas}) = 0.8$$

Fusion conjonctive (min)

$$\pi(\text{Objet}) = \min(0.9, 0.4) = 0.4$$
$$\pi(\text{Pas}) = \min(0.2, 0.8) = 0.2$$

Interprétation : conflit visible

Gestion du conflit

Observation

- Les capteurs peuvent être contradictoires

Avantages de la théorie des possibilités

- Le conflit apparaît naturellement (valeurs faibles)
- Pas de normalisation obligatoire
- Possibilité de modéliser l'ignorance

Stratégies

- Fusion prudente : $\min$
- Fusion tolérante : $\max$
- Pondération des sources

Probabilités vs Possibilités

	Probabilités	**Possibilités**
Somme	= 1	non contrainte
Incertitude	aléatoire	imprécision
Conflit	difficile	explicite
Complexité	élevée	faible

→ **Les possibilités sont adaptées aux données imparfaites**

Fusion de données : fonctions de croyance

Pourquoi aller au-delà des probabilités ?

- Difficulté à modéliser l'ignorance
- Besoin de représenter l'incertitude partielle

Solution : théorie des fonctions de croyance

- Représente incertitude + ignorance
- Permet de modéliser le conflit
- Fusion robuste d'informations hétérogènes

Notions de base

Cadre de discernement

$$\Omega = \{\text{Objet}, \text{Pas d'objet}\}$$

Masse de croyance

$$m : 2^{\Omega} \rightarrow [0, 1]$$

$$\sum_{A \subseteq \Omega} m(A) = 1$$

Interprétation

- $m(A)$: croyance attribuée à A
- $m(\Omega)$: ignorance

Croyance et plausibilité

Fonctions dérivées

$$Bel(A) = \sum_{B \subseteq A} m(B)$$

$$Pl(A) = \sum_{B \cap A \neq \emptyset} m(B)$$

Interprétation

- $Bel(A)$: certitude minimale
- $Pl(A)$: possibilité maximale

$$Bel(A) \leq P(A) \leq Pl(A)$$

Règle de combinaison de Dempster

Fusion de deux sources m_1 et m_2

$$m(A) = \frac{1}{1-K} \sum_{B \cap C = A} m_1(B)\, m_2(C)$$

Conflit

$$K = \sum_{B \cap C = \emptyset} m_1(B)\, m_2(C)$$

Idée

- Redistribution du conflit
- Fusion normalisée

Exemple numérique

$\Omega = \{\text{Objet}, \text{Pas}\}$

Capteur 1

$$m_1(\text{Objet}) = 0.6, \quad m_1(\Omega) = 0.4$$

Capteur 2

$$m_2(\text{Pas}) = 0.7, \quad m_2(\Omega) = 0.3$$

Conflit

$$K = 0.6 \times 0.7 = 0.42$$

Interprétation

- Conflit élevé entre les sources
- L'ignorance joue un rôle clé

Gestion du conflit

Observation

- Les sources peuvent fortement se contredire

Avantages

- Le conflit est **quantifié** (K)
- L'ignorance est explicitement modélisée
- Fusion flexible

Attention

- Si K est proche de 1 $\rightarrow$ fusion instable

Comparaison des approches

	Probabilités	**Croyances**
Ignorance	non	oui
Conflit	implicite	explicite (K)
Flexibilité	moyenne	élevée
Complexité	faible	plus élevée

$\rightarrow$ **Approche adaptée aux données incertaines et contradictoires**

Questions?

Références

- Les approches classiques de la fusion de données - Michèle Rombaut.
- The KITTI Vision Benchmark Suite: A project of Karlsruhe Institute of Technology and Toyota Technological Institute at Chicago
- nuScenes by Motional: large-scale autonomous driving dataset